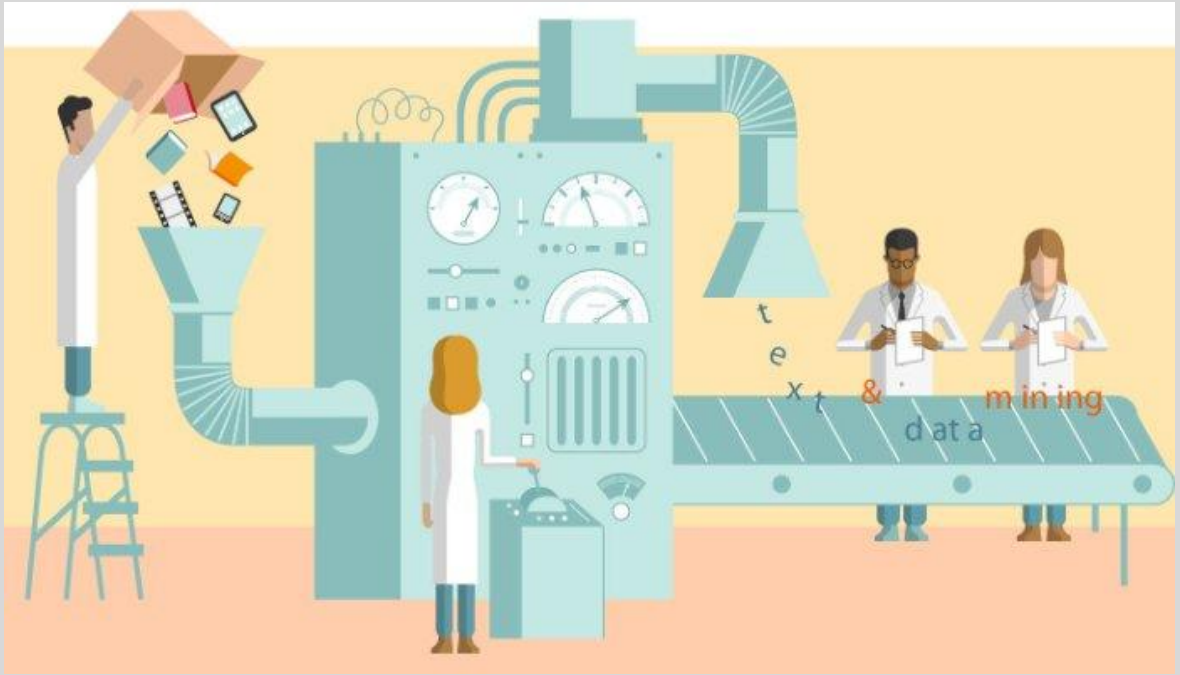

DigitalHouse > Coding School

DATA SCIENCE

MÓDULO 2

Limpieza de datos con Pandas

OBJETIVOS DE LA CLASE

1. Aprender sobre las operaciones que abarca la limpieza de datos y métodos asociados
2. Aprender a usar herramientas para la limpieza de datos ..apply(), .applymap() y expresiones lambda
3. Conocer e implementar las técnicas del “tidy data”
4. Introducción a expresiones regulares

Limpieza y preparación de datos

Limpieza y preparación de datos

- En 2009 Mike Driscoll (data scientist y CEO de Metamarkets) popularizó el término **“data munging”** para referirse al **arduo proceso de limpiar, preparar y validar los datos**

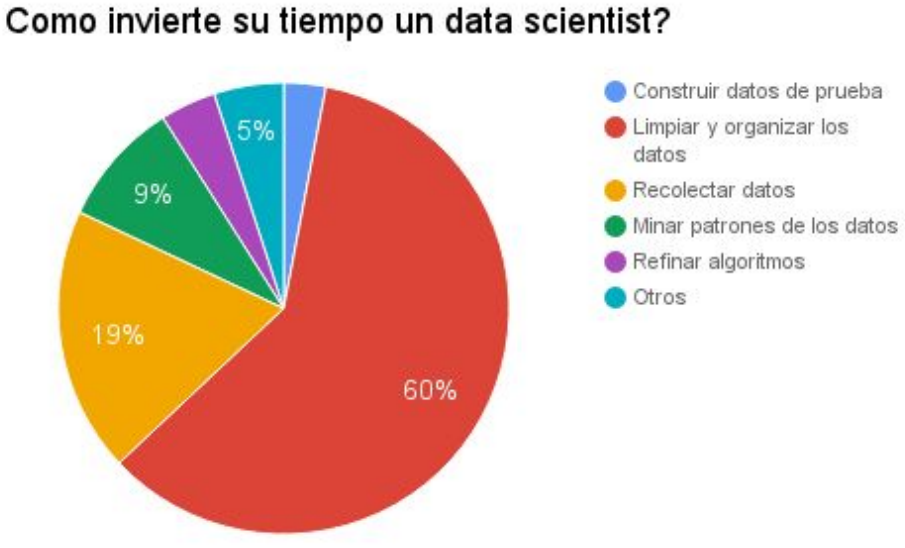

Fuente:
http://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/

Limpieza y preparación de datos

- **En 2013, Josh Wills** (ex director de Data Science de Cloudera y posterior Director of Data Engineering en Slack) comenta: "**I'm a data janitor.** That's the sexiest job of the 21st century. It's very flattering, but it's also a little baffling."

Traducción:
En Data Science, se invierte un 80% del tiempo en preparar los datos y el 20% restante en quejarse de la necesidad de preparar los datos

Limpieza de datos con Pandas

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

1. Resolver problemas de formato y asignar los tipos correctos de datos: Por ejemplo cuando al pasar de CSV a Pandas una fecha no se importa correctamente. Ej: 20090609231247 en lugar de 2009-06-09 23:12:47.

El formato en que se encuentran los datos va a afectar nuestro análisis por varias razones. Por ejemplo, las operaciones que se pueden realizar dependen del tipo de datos. Además algunos tipos ocupan menos espacio en memoria que otros.

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

2. Estandarizar categorías: Cuando los datos se recolectaron con un sistema que no tiene los valores tipificados, valores que representan las mismas categorías pueden estar expresados de forma distinta, por ejemplo Arg, AR y Argentina.

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

3. **Corregir valores erróneos:** Por ejemplo un valor numérico o inválido para describir el género. O una edad representada por un número negativo o mucho mayor que 100.

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

4. Completar datos faltantes: Los datasets del mundo real suelen venir con datos faltantes que responden a información que se perdió o nunca se recolectó. Existen varias técnicas para completar datos faltantes. Al proceso de completar datos faltantes se lo llama "**imputación**".

Limpieza de datos

La limpieza es un paso necesario en todo proyecto de datos.
Podemos resumir el proceso de limpieza de datos refiriéndonos a las siguientes cinco tareas:

5. Organizar correctamente el dataset: Es importante estructurar las filas y columnas de la forma más conveniente. Para hacerlo se pueden aplicar las reglas del "**tidy data**".

Representación de datos faltantes

- Los datasets del mundo real siempre tienen **datos faltantes**
- Cada lenguaje/framework tiene su forma de lidiar con estos
- Pandas utiliza los valores **None, NaN o NaT** debido a que se basa en Numpy
    - **None:** objeto de Python que representa ausencia de dato
    - **NaN:** definición de valor faltante de floats
    - **NaT:** se utiliza para valores faltantes del tipo Timestamp

None VS np.nan

```
In [1]: import numpy as np
        import pandas as pd

In [2]: vals1 = np.array([1, None, 3, 4])
        vals1

Out[2]: array([1, None, 3, 4], dtype=object)
```

```
In [5]: vals2 = np.array([1, np.nan, 3, 4])
        vals2.dtype

Out[5]: dtype('float64')
```

Cuando tenemos un objeto None incluído en una serie, el “upcasting” de Numpy se resuelve a “object”. Cuando tenemos un np.nan, conservamos una columna de tipo float y podemos seguir operando de manera eficiente.

Valores faltantes

- En general todo conjunto de datos suele tener datos faltantes (ya sea porque esos datos no fueron recolectado o nunca existieron)
    - Debemos poder detectar, rellenar o eliminar datos faltantes
    - Hay que utilizar conocimiento del dominio para definir cuáles datos faltantes se completarán y cómo.
    - Pandas ofrece varias formas de hacer esto.

Análisis con datos completos.

Una forma de proceder consiste en eliminar los registros que presentan algún dato faltante:

- Ventaja: fácil implementación
- Desventaja: pérdida importante de información, posibles sesgos en los estimadores de los parámetros.

Este método asume que la falta de respuesta se generó de forma aleatoria, lo que por lo general no sucede.

Si los datos que faltan son pocos y al azar, entonces este método es el ideal.

Métodos de imputación

Imputación Simple:

Consiste en asignar un valor por cada dato faltante a partir de la propia variable o las demás variables para lograr una base de datos completa.

Imputación Múltiple:

A cada valor faltante se le asigna un grupo de *m* valores, generando *m* bases de datos completas. En cada una de las *m* bases de datos se estiman los parámetros de interés y luego se combinan los resultados obtenidos.

Imputación por Media

Se puede completar los valores faltantes reemplazandolos **por la media** de la serie o **por la media condicionada** a determinada categoría. Por ejemplo, dado un valor de estatura faltante para una mujer, reemplazarlo por la media de las mujeres.

Este enfoque tiene ventajas y desventajas:

- Ventaja: Es muy probable acercarme al verdadero valor del dato faltante
- Desventajas:
  - Reduzco artificialmente la variabilidad y la aleatoriedad de los datos, lo cual me puede llevar a conclusiones equivocadas.
  - Si existía correlación entre esta variable y otras, ese valor puede verse afectado.

Métodos de imputación

Imputación Hot Deck

Consisten en completar con un dato existente de la muestra, siguiendo algún criterio. Pueden ser aleatorios (se elige un elemento al azar), secuencial (se completa con el valor inmediatamente anterior o posterior) o vecino más cercano.

Imputación por Regresión

Se emplean modelos de regresión para estimar el dato que falta a partir de las demás variables del data set.

Métodos de imputación

DigitalHouse > Coding School

Introducción a imputación en Pandas

El método ***fillna()*** de Pandas, permite varios tipos de imputación que puede especificarse en el parámetro "method":

- Completar los datos con valores definidos por fuera del data set. ***(method = None)*** ya que se ingresa directamente como argumento el valor con el que se imputará.

- Completar los datos faltantes con el valor anterior o el siguiente (ideal para series de tiempo) ***(method = ffill)*** *o* ***(method = bfill)***

- Completar por la media, moda o la mediana. ***dff.fillna(dff.mean())***

Las reglas del “tidy data”

- Decimos que un dataset está ordenado cuando:
  - Cada variable es una columna
  - Cada observación es una fila
  - Cada tipo de unidad observacional forma una tabla
- Algunas definiciones:
  - Variable: Es la medición de un atributo, por ejemplo, peso, altura, etc
  - Valor: Es la medida que toma una variable para una observación
  - Observación: Todas las observaciones toman el mismo tipo de valores para cada variable.

Tidy data: ejemplos

Messy data

	treatmenta	treatmentb
John Smith	—	2
Jane Doe	16	11
Mary Johnson	3	1

	John Smith	Jane Doe	Mary Johnson
treatmenta	—	16	3
treatmentb	2	11	1

Tidy data

name	trt	result
John Smith	a	—
Jane Doe	a	16
Mary Johnson	a	3
John Smith	b	2
Jane Doe	b	11
Mary Johnson	b	1

- Cada unidad observacional debería ser un tratamiento sobre una persona
- En los formatos “messy data”, si quisiera agregar tratamientos que no aplican a todas las personas se llenaría el dataset de valores nulos.

Herramientas para la limpieza de datos

Expresiones lambda

- Recordemos brevemente cómo construir una función usando def:
  - Este forma de declarar funciones sirve, entre otras cosas, para reducir código duplicado y para modularizar el código.

```
>>> def square(x): return x**2
>>> square(10)
100
```

- ¿Tendría sentido definir una función de este modo si vamos a invocar dicha función una única vez?
  - Las funciones lambda pueden ser directamente definidas en el código que las va a utilizar y sin necesidad de otorgarles un nombre (son funciones anónimas).
  - Toman una única expresión y no contienen la expresión return.
  - Se definen en una única línea

```
>>> square = lambda x: x**2
>>> square(10)
100
```

La función apply() en Pandas

- El método **apply()** permite aplicar cualquier función a los elementos de un Dataframe. Se puede utilizar:
    - Por columna: **df.apply(mi_funcion)** (iterando por filas)
    - Por fila **df.apply(mi_funcion, axis = 1)** (iterando por cols)
    - Elemento por elemento **df.applymap(mi_funcion)**
- **.apply()** también se puede utilizar sobre una Serie, elemento por elemento.
- Una buena propiedad de **apply()** es que permite aplicar las operaciones vectorizadas de numpy.

Expresiones regulares

¿Qué son las expresiones regulares y para qué sirven?

Una expresión regular es una **secuencia de caracteres** que define un **patrón de búsqueda** de texto. Las regex constituyen lenguaje muy flexible que sirve para identificar y extraer información de un cuerpo de caracteres **no estructurado**.

Ejemplos:

- identificar direcciones de correo electrónico
- identificar DNI, CUIT, CUIL, etc.

Los **metacaracteres especiales** son aquellos que no se encuentran a sí mismos, sino que indican que se debe *matchear* algo de forma no literal, o que afectan a otras partes de la regex repitiendo caracteres o cambiando su significado.

Algunos metacaracteres frecuentes:

\d Cualquier dígito del 0 al 9
\w Cualquier caracter alfanumérico (A-Z, a-z, 0-9 y _)
\s Cualquier espacio en blanco (espacio, tabulado, nueva línea, etc.)
. Cualquier caracter con excepción de nueva línea (\n)

Y sus complementos:

\D Todo menos cualquier dígito
\W Todo menos cualquier carácter alfanumérico
\S Todo menos cualquier espacio en blanco

Cuantificadores:

***** Cero o más del elemento anterior
+ Uno o más del elemento anterior
{min,max} Definen mínimos y máximos de repetición
? Opcional, o cero o uno del elemento anterior

Ejemplos:

\d+ Encuentra un número o más
.* Encuentra cero o más de cualquier caracter
\w{2,6} Encuentra un conjunto de caracteres alfanuméricos con una longitud que va de 2 a 6 caracteres

Otros metacaracteres importantes:

[ ] Definen un conjunto de caracteres
[A-Za-z0-9_] Definen rangos

( ) Definen un grupo de captura
| Operador "o"
**** Escapa los caracteres especiales

Metacaracteres de posición:

^ Comienzo de un *string* (o negación dentro de un conjunto, [^])
$ Final de un *string*
\b Límite de palabra

Documentación oficial:

https://docs.python.org/3/library/re.html

https://docs.python.org/3/howto/regex.html

Sitios web para practicar:

https://regexr.com/

https://regex101.com/