

DigitalHouse >
Coding School

DATA SCIENCE

MODULO 5

Series de Tiempo I

Series de Tiempo



1

Introducir los datos de series temporales, entender el concepto de estacionariedad.

2


Presentar modelos simples para datos de series temporales

3


Comprender el esquema de validación cruzada a aplicar con datos de series temporales

Introducción. Series de Tiempo






Seasonal plots



Seasonal subseries plots



Patrones en series de tiempo

- El **patrón de tendencia** existe cuando a largo plazo hay un Incremento o disminución de los datos.
- El **patrón estacional** existe cuando una serie es influenciada por factores estacionales (por ejemplo, el trimestre del año, mes o día de la semana).
- Existe un **patrón cíclico** cuando los datos exhiben aumentos y caídas que no son de periodo fijo (duración normalmente de al menos 2 años).

Diferencias entre patrones en series de tiempo

- El patrón estacional tiene longitud constante mientras que el patrón cíclico tiene longitud variable
- La duración media del ciclo es más larga que la duración del patrón estacional.
- La magnitud de ciclo es más variable que la magnitud del patrón estacional
- El tiempo de los picos y valles es predecible con datos estacionales, pero impredecibles a largo plazo en el patrón cíclico.

$$Y_t = f(S_t, T_t, E_t)$$

Y_t = data at period t

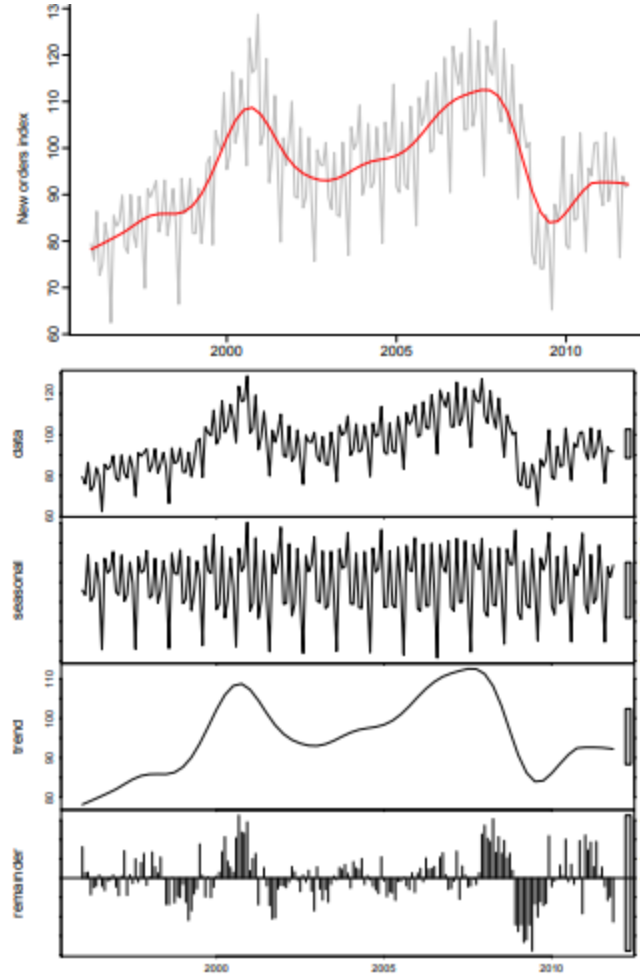
S_t = seasonal component at period t

T_t = trend component at period t

E_t = remainder (or irregular or error) component at period t

Additive decomposition: $Y_t = S_t + T_t + E_t$.


Introducción. Series de Tiempo




STL decomposition

- Muy versátil y robusto.
- El componente estacional puede cambiar con el tiempo y la tasa de cambio es controlada por el usuario.
- Suavidad de tendencia-ciclo también controlado por el usuario.
- Robusto a los outliers
- Sólo aditivo.


Introducción. Series de Tiempo




Introducción. Series de Tiempo




Introducción. Series de Tiempo



Introducción. Series de Tiempo





- Las series temporales económicas a menudo son analizadas después de calcular sus logaritmos o las variaciones en sus logaritmos.
- Una razón para ello es que muchas series económicas, tales como el producto interior bruto (PIB), presentan un crecimiento que es aproximadamente exponencial, es decir, a largo plazo la serie tiende a crecer a un determinado porcentaje medio anual; si es así, el logaritmo de la serie crece de forma aproximadamente lineal.

Introducción a los datos de series temporales y correlación serial

- Otra razón es que la desviación típica de muchas series temporales económicas es aproximadamente proporcional a su nivel, es decir, la desviación típica se puede expresar correctamente un porcentaje del nivel de las series; si es así, entonces la desviación típica del logaritmo de la serie es aproximadamente constante.
- En cualquier caso, resulta útil transformar las series para que las variaciones en las series transformadas sean variaciones proporcionales (o porcentuales) de la serie original, y esto se logra tomando el logaritmo de las series.

- Covarianza y correlación: medida medida de la relación lineal entre dos variables (Y e X).
- Autocovarianza y autocorrelación: medida de la relación lineal entre los valores rezagados de una series de tiempo y.

$$c_k = \frac{1}{T} \sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})$$


c_k es la autocovarianza. Si dividimos por la varianza obtenemos las autocorrelaciones.

$$r_k = c_k / c_0$$



- Las autocovarianzas y autocorrelaciones j -ésimas poblacionales del pueden ser estimadas mediante las autocovarianzas y autocorrelaciones j -ésimas muestrales

- r_1 indica cómo los valores sucesivos de y se relacionan con cada uno otro
- r_2 indica cómo se relacionan los valores de y con dos periodos separados el uno del otro
- r_k es casi lo mismo que la correlación muestral entre y_t y y_{t-k} .

- Las autocorrelaciones en los lags 1,2.. forman la función de autocorrelación.
 - o ACF.
- El gráfico se conoce como correlograma.




Introducción a los datos de series temporales y correlación serial




Introducción a los datos de series temporales y correlación serial

¿Cuál es cual?


1. Daily morning temperature of a cow




2. Accidental deaths in USA (monthly)




3. International airline passengers




4. Annual mink trappings (Canada)




A




B



C



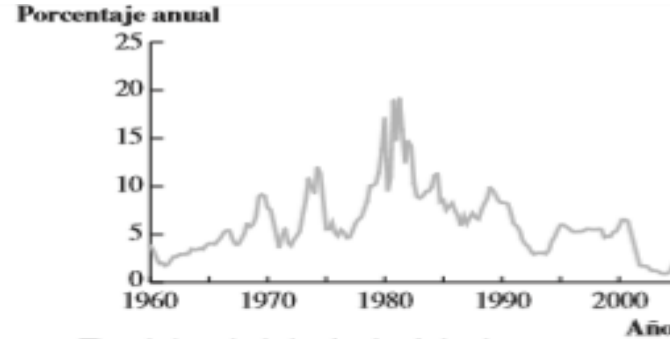
D



Introducción a los datos de series temporales y correlación serial.

- Otros ejemplos de series temporales económicas
 - el tipo de interés de los fondos federales en EE.UU.
 - el tipo de cambio entre el dólar y la libra esterlina
 - el logaritmo del producto interior bruto de Japón
 - la rentabilidad diaria en el índice del mercado de acciones Standard and Poor's 500 (S&P 500).


Introducción a los datos de series temporales y correlación serial.



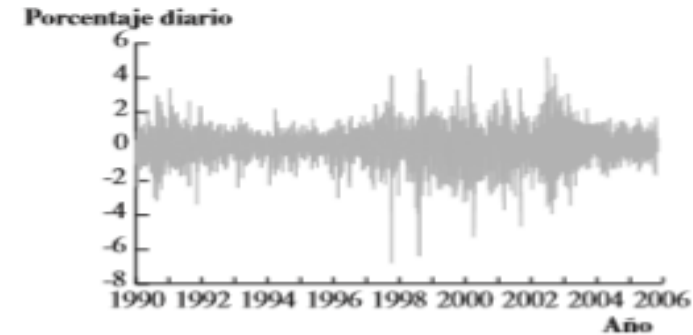
(a) Tipo de interés de los fondos federales



(b) Tipo de cambio dólar EE.UU./libra esterlina



(c) Logaritmo del PIB de Japón



(d) Variación porcentual de los valores diarios del índice de acciones NYSE Composite

- Algunos métodos simples de forecasting

- Average

$$\hat{y}_{T+h|T} = \bar{y} = (y_1 + \dots + y_T)/T$$

- Naive

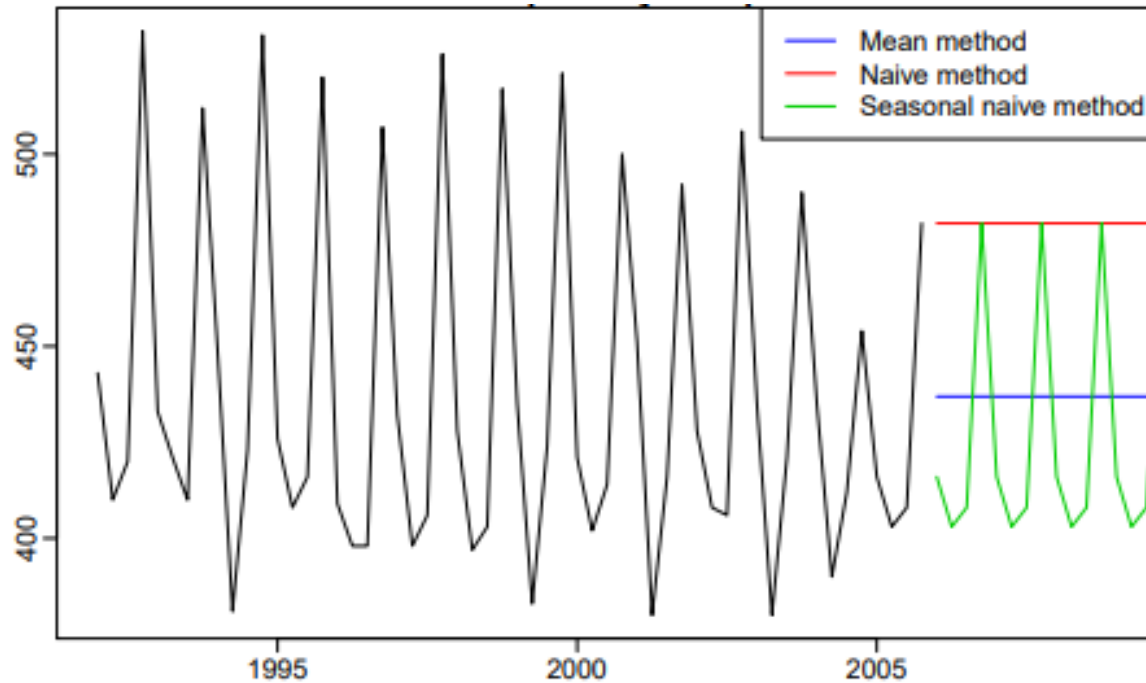
$$\hat{y}_{T+h|T} = y_T$$

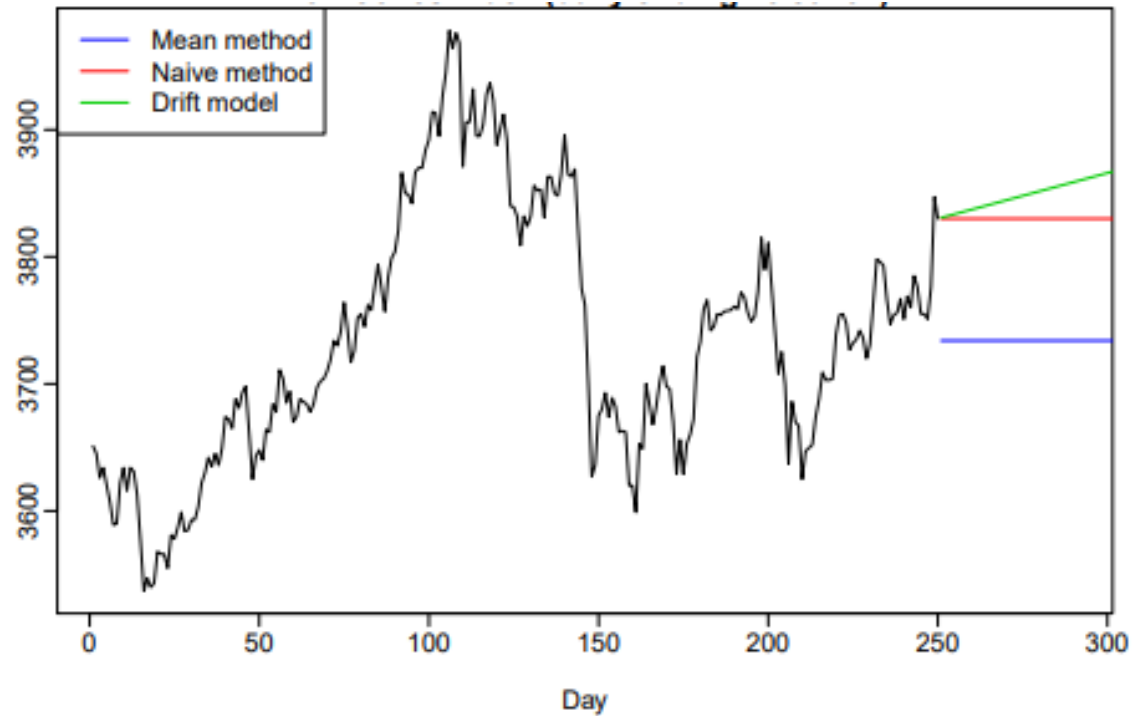
- Seasonal naive

Forecasts: $\hat{y}_{T+h|T} = y_{T+h-km}$ where $m =$ seasonal period and $k = \lfloor (h-1)/m \rfloor + 1$.

- Algunos métodos simples de forecasting
 - Drift method

$$\begin{aligned}\hat{y}_{T+h|T} &= y_T + \frac{h}{T-1} \sum_{t=2}^T (y_t - y_{t-1}) \\ &= y_T + \frac{h}{T-1} (y_T - y_1).\end{aligned}$$








- ¿Qué características nos gustaría ver en los residuos?
- Usemos un modelo ingenuo para el Dow Jones


$$\hat{y}_{t|t-1} = y_{t-1}$$


$$e_t = y_t - y_{t-1}$$

















$r_1 = 0.013$
 $r_2 = -0.163$
 $r_3 = 0.163$
 $r_4 = -0.259$
 $r_5 = -0.198$
 $r_6 = 0.064$
 $r_7 = -0.139$
 $r_8 = -0.032$
 $r_9 = 0.199$
 $r_{10} = -0.240$





- Suponemos que los residuos son ruido blanco (no correlacionado, media cero, varianza constante).
- Si no lo son, entonces hay información que quede en los residuos que deben usarse en el forecast.
- En el ACF de los residuos de un método de forecast esperamos que estos se vean como ruido blanco.

Residuos Dow Jones



Parecen ruido blanco pero recuerde que ACF es un problema de multiple testing.

Test de Box Pierce

$$Q = T \sum_{k=1}^h r_k^2$$

donde h es el máximo rezago considerado y T es el tamaño muestral

Si los datos son ruido blanco entonces Q tiene distribución Chi Cuadrado con (h-K) grados de libertad, donde K es el número de parámetros del modelo. .

$$\text{MAE} = T^{-1} \sum_{t=1}^T |y_t - \hat{y}_{t|t-1}|$$

$$\text{MSE} = T^{-1} \sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 \quad \text{RMSE} = \sqrt{T^{-1} \sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2}$$

$$\text{MAPE} = 100 T^{-1} \sum_{t=1}^T |y_t - \hat{y}_{t|t-1}| / |y_t|$$

- MAE, MSE, RMSE son todos dependientes de la escala.
- MAPE es scale independent pero sólo es razonable si y_t es positivo para todo t y si la serie tiene un cero natural.

Mean Absolute Scaled Error

$$\text{MASE} = T^{-1} \sum_{t=1}^T |y_t - \hat{y}_{t|t-1}| / Q$$

Donde Q es una medida de la escala de la serie

Para series no estacionales

$$Q = (T - 1)^{-1} \sum_{t=2}^T |y_t - y_{t-1}|$$

En series con

$$Q = (T - m)^{-1} \sum_{t=m+1}^T |y_t - y_{t-m}|$$

- State space perspective

- Observed data: y_1, \dots, y_T .
- Unobserved state: $\mathbf{x}_1, \dots, \mathbf{x}_T$.

$$\text{Forecast } \hat{y}_{T+h|T} = E(y_{T+h} | \mathbf{x}_T)$$

La varianza del forecast $\text{Var}(y_{T+h} | \mathbf{x}_T)$

Un intervalo de predicción o “interval forecast” es un rango de valores para y en $T+h$ que tiene alta probabilidad

$$\begin{array}{ll} \text{Forecast equation} & \hat{y}_{t+h|t} = \ell_t \\ \text{Smoothing equation} & \ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1} \end{array}$$

$$\ell_1 = \alpha y_1 + (1 - \alpha)\ell_0$$

$$\ell_2 = \alpha y_2 + (1 - \alpha)\ell_1 = \alpha y_2 + \alpha(1 - \alpha)y_1 + (1 - \alpha)^2\ell_0$$

$$\ell_3 = \alpha y_3 + (1 - \alpha)\ell_2 = \sum_{j=0}^2 \alpha(1 - \alpha)^j y_{3-j} + (1 - \alpha)^3\ell_0$$

\vdots

$$\ell_t = \sum_{j=0}^{t-1} \alpha(1 - \alpha)^j y_{t-j} + (1 - \alpha)^t\ell_0$$

Forecast equation

$$\hat{y}_{t+h|t} = \sum_{j=1}^t \alpha(1-\alpha)^{t-j} y_j + (1-\alpha)^t \ell_0, \quad (0 \leq \alpha \leq 1)$$

Observation	Weights assigned to observations for:			
	$\alpha = 0.2$	$\alpha = 0.4$	$\alpha = 0.6$	$\alpha = 0.8$
y_t	0.2	0.4	0.6	0.8
y_{t-1}	0.16	0.24	0.24	0.16
y_{t-2}	0.128	0.144	0.096	0.032
y_{t-3}	0.1024	0.0864	0.0384	0.0064
y_{t-4}	$(0.2)(0.8)^4$	$(0.4)(0.6)^4$	$(0.6)(0.4)^4$	$(0.8)(0.2)^4$
y_{t-5}	$(0.2)(0.8)^5$	$(0.4)(0.6)^5$	$(0.6)(0.4)^5$	$(0.8)(0.2)^5$

- Component form

Forecast equation	$\hat{y}_{t+h t} = \ell_t$
Smoothing equation	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$

- State Space form


Observation equation	$y_t = \ell_{t-1} + e_t$
State equation	$\ell_t = \ell_{t-1} + \alpha e_t$

$$e_t = y_t - \ell_{t-1} = y_t - \hat{y}_{t|t-}$$

Es el within sample one step forecast error

ℓ_t es el estado inobservable


Necesitamos elegir valores par α y ℓ_0



- Busquemos esos valores minimizando MSE

$$\text{MSE} = \frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_{t|t-1})^2 = \frac{1}{T} \sum_{t=1}^T e_t^2.$$

- A diferencia de regresión no hay solución de forma cerrada usamos optimización numérica.



- Multistep forecast

$$\hat{y}_{T+h|T} = \hat{y}_{T+1|T}, \quad h = 2, 3, \dots$$

- Una función de pronóstico "plana".
- Recuerde, un pronóstico es una media estimada de un valor futuro así que sin tendencia, sin estacionalidad, y sin otros patrones los pronósticos son constantes.

- Holt extiende SES para forecasting de series con tendencias.
- Dos parámetros de smoothing alpha y beta, ambos entre 0 y 1.

$$\begin{aligned}\hat{y}_{t+h|t} &= \ell_t + hb_t \\ \ell_t &= \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}) \\ b_t &= \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}\end{aligned}$$

El componente ℓ_t estima el nivel de la serie en el momento t

El componente b_t estima la pendiente de la serie en el momento t

Holt's linear trend

- Component form

Forecast	$\hat{y}_{t+h t} = \ell_t + hb_t$
Level	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
Trend	$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$

- State Space form

Observation equation	$y_t = \ell_{t-1} + b_{t-1} + e_t$
State equations	$\ell_t = \ell_{t-1} + b_{t-1} + \alpha e_t$
	$b_t = b_{t-1} + \beta e_t$

Holt's linear trend

$$\beta = \alpha \beta^*$$

$$e_t = y_t - (\ell_{t-1} + b_{t-1}) = y_t - \hat{y}_{t|t-1}$$

Necesito estimar $\alpha, \beta, \ell_0, b_0$

Multiplicative versión del método de Holt

- State Space form

Forecast equation	$\hat{y}_{t+h t} = \ell_t b_t^h$
Observation equation	$y_t = (\ell_{t-1} b_{t-1}) + e_t$
State equations	$\ell_t = \ell_{t-1} b_{t-1} + \alpha e_t$ $b_t = b_{t-1} + \beta e_t / \ell_{t-1}$


Multiplicative versión del método de Holt

- Gardner y McKenzie (1985) sugirieron que las tendencias deben ser "amortiguadas" para ser más conservadoras para horizontes de pronóstico más largos.
- Parámetro de amortiguamiento $0 < \phi < 1$.
- State Space form


Forecast equation	$\hat{y}_{t+h t} = \ell_t + (\phi + \phi^2 + \dots + \phi^h)b_t$
Observation equation	$y_t = \ell_{t-1} + \phi b_{t-1} + e_t$
State equations	$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha e_t$ $b_t = \phi b_{t-1} + \beta e_t$

- Si $\phi = 1$ idéntico al Holt's linear trend
- Short run forecasts con tendencia, a largo plazo constantes

$$h \rightarrow \infty, \hat{y}_{T+h|T} \rightarrow \ell_T + \phi b_T / (1 - \phi)$$



Exponential Smoothing



Holt-Winter additive method

- Holt y Winters extendieron el método de Holt para capturar estacionalidad
- Tres ecuaciones de suavizado: una para el nivel, una por tendencia, y una por estacionalidad.
- Parámetros : m es el período de la estacionalidad

$$0 \leq \alpha \leq 1, 0 \leq \beta \leq 1, 0 \leq \gamma \leq 1 - \alpha$$

Holt-Winter additive method

- State Space form

$$\begin{aligned}\hat{y}_{t+h|t} &= \ell_t + hb_t + s_{t-m+h_m^+} & h_m^+ &= \lfloor (h-1) \bmod m \rfloor + 1 \\ y_t &= \ell_{t-1} + b_{t-1} + s_{t-m} + e_t \\ \ell_t &= \ell_{t-1} + b_{t-1} + \alpha e_t \\ b_t &= b_{t-1} + \beta e_t \\ s_t &= s_{t-m} + \gamma e_t.\end{aligned}$$

Holt-Winter damped method

- State Space form

$$\begin{aligned}y_t &= (\ell_{t-1} + \phi b_{t-1}) s_{t-m} + e_t \\ \ell_t &= \ell_{t-1} + \phi b_{t-1} + \alpha e_t / s_{t-m} \\ b_t &= \phi b_{t-1} + \beta e_t / s_{t-m} \\ s_t &= s_{t-m} + \gamma e_t / (\ell_{t-1} + \phi b_{t-1}).\end{aligned}$$

- Criterio de Información de Akaike

$$AIC = -2 \log(\text{Likelihood}) + 2p$$

donde p es el número de parámetros estimados

- Buscamos minimizar el AIC.

- Criterio de Información de Akaike corregido por small sample bias

$$AIC_c = AIC + \frac{2(p+1)(p+2)}{n-p}$$

donde p es el número de parámetros estimados

- Buscamos minimizar el AIC.


- Criterio de Información Bayesiano (Schwartz)

$$\text{BIC} = \text{AIC} + p(\log(n) - 2)$$

- Aplique cada modelo que sea apropiado para el datos. Optimizar parámetros y valores iniciales utilizando MLE (o algún otro criterio).
- Seleccione el mejor método utilizando AICc:
- Producir pronósticos utilizando el mejor método.
- Obtener intervalos de predicción utilizando el modelo de espacio de estado subyacente.

Validación del modelo







Traditional evaluation



Standard cross-validation




Time series cross-validation




Traditional evaluation



Standard cross-validation



Time series cross-validation



Anexo: más sobre smoothing



Taylor multiplicative dampening

$$\hat{y}_{t+h|t} = l_t b_t^{(\phi + \phi^2 + \dots + \phi^h)}$$

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} b_{t-1}^\phi)$$

$$b_t = \beta^* (l_t / l_{t-1}) + (1 - \beta^*) b_{t-1}^\phi$$


- Si $\phi = 1$ exponential trend method
- Los forecast convergen a $l_T + b_T^{\phi/(1-\phi)}$ cuando h se hace arbitrariamente grande.

Holt-Winter additive method

- Métodos de suavizado exponencial.
 - Algoritmos que devuelven las previsiones puntuales.
- Innovations State space models con innovaciones
 - Genera los mismos pronósticos puntuales pero también puede generar intervalos de forecast.
- Un proceso estocástico generador de datos que puede generar una distribución completa de forecasts.
- Permite una selección de modelo adecuada.

		Seasonal Component		
		N (None)	A (Additive)	M (Multiplicative)
Trend Component	N (None)	N,N	N,A	N,M
	A (Additive)	A,N	A,A	A,M
	A _d (Additive damped)	A _d ,N	A _d ,A	A _d ,M
	M (Multiplicative)	M,N	M,A	M,M
	M _d (Multiplicative damped)	M _d ,N	M _d ,A	M _d ,M

General notation E T S : ExponenTial Smoothing



 Error Trend Seasonal

Trend Component		Seasonal Component		
		N (None)	A (Additive)	M (Multiplicative)
N	(None)	N,N	N,A	N,M
A	(Additive)	A,N	A,A	A,M
A _d	(Additive damped)	A _d ,N	A _d ,A	A _d ,M
M	(Multiplicative)	M,N	M,A	M,M
M _d	(Multiplicative damped)	M _d ,N	M _d ,A	M _d ,M

- N,N: Simple exponential smoothing
- A,N: Holt's linear method
- A_d,N: Additive damped trend method
- M,N: Exponential trend method
- M_d,N: Multiplicative damped trend method
- A,A: Additive Holt-Winters' method
- A,M: Multiplicative Holt-Winters' method

Holt-Winter additive method

- Todos los modelos ETS pueden ser escritos en innovations state space form.
- Las versiones aditivas y multiplicativas dan los mismos point forecasts pero diferentes intervalos de predicción.

Observation equation	$y_t = l_{t-1} + \varepsilon_t,$
State equation	$l_t = l_{t-1} + \alpha \varepsilon_t$

$$e_t = y_t - \hat{y}_{t|t-1} = \varepsilon_t$$

$$\varepsilon_t \sim \text{NID}(0, \sigma^2)$$

$$\mathbf{x}_t = (\ell_t, b_t, s_t, s_{t-1}, \dots, s_{t-m+1})$$

$$\varepsilon_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

$$y_t = \underbrace{h(\mathbf{x}_{t-1})}_{\mu_t} + \underbrace{k(\mathbf{x}_{t-1})\varepsilon_t}_{e_t}$$

$$\mathbf{x}_t = f(\mathbf{x}_{t-1}) + g(\mathbf{x}_{t-1})\varepsilon_t$$

- Errores aditivos

$$k(x) = 1. \quad y_t = \mu_t + \varepsilon_t$$

- Errores multiplicativos

$$k(\mathbf{x}_{t-1}) = \mu_t. \quad y_t = \mu_t(1 + \varepsilon_t). \\ \varepsilon_t = (y_t - \mu_t)/\mu_t \text{ is relative error.}$$