



DATA SCIENCE

Procesamiento Distribuído con Apache Spark



- 1 Introducción a Big Data
- 2 Introducción a Apache Spark
- 3 Spark Core
- 4 Spark SQL
- 5 Conclusiones

Presentación del Especialista





Juan Martín Pampliega - Ingeniero en Informática ITBA Co Founder Mutt Data - Profesor de Posgrado ITBA

- Comencé a trabajar con herramientas de Big Data en 2010 con Hadoop.
- Trabajé y lideré proyectos en Globant (Google), Despegar, Socialmetrix y Jampp.
- Utilicé distintas herramientas desde DataFlow (Google), Pig, HBase, Hadoop, Hive, Spark, PrestoDB, Airflow, AWS Kinesis, AWS Lambda, Flume, etc.
- Actualmente soy Co Founder en Mutt Data, una empresa enfocada en la consultoría y desarrollo de proyectos de Big Data y Data Science.

Big Data



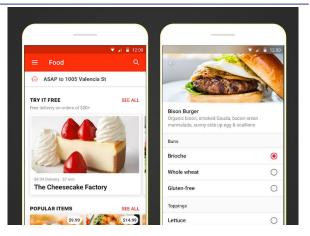
Todo comienza con eventos en una base



Inicialmente armamos el sistema transaccional en una base:

login, create user, create restaurant, create order, view order, receive order, etc.

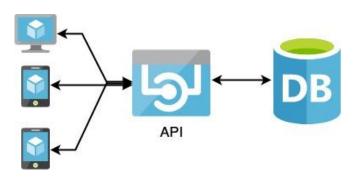
This type of operations mostly involve INSERT/SELECT/UPDATE/DELETE operations over a small group of rows.



OLTP (OnLine Transactional Processing)

Like:

INSERT INTO orders
VALUES ('User1', 'Restaurant1', 'cheeseburger');



Pero los usuarios hacen preguntas



6

Cuantas órdenes se hicieron ayer?

Cual es el ítem más pedido?

Dónde se hacen la mayoría de mis pedidos?

Cuanta distancia recorre un delivery en promedio por día?

Estas preguntas involucran agregaciones sobre muchas filas (OLAP)

SELECT day(date), count(1)

FROM orders

WHERE date = YESTERDAY

GROUP BY day(date)



Una base de datos no es suficiente



Dónde están los deliveries en cada momento del día?

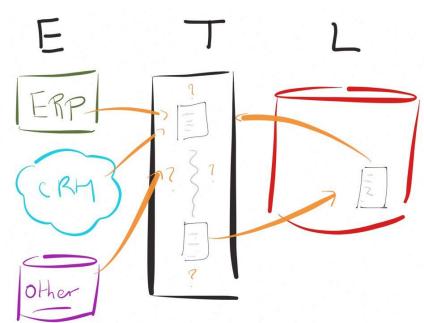
Cuántos usuarios únicos tuvimos cada día?

Cual va a ser el tiempo estimado de delivery de una hamburguesa el sábado a las 20hs?

OLAP (OnLine Analytical Processing)

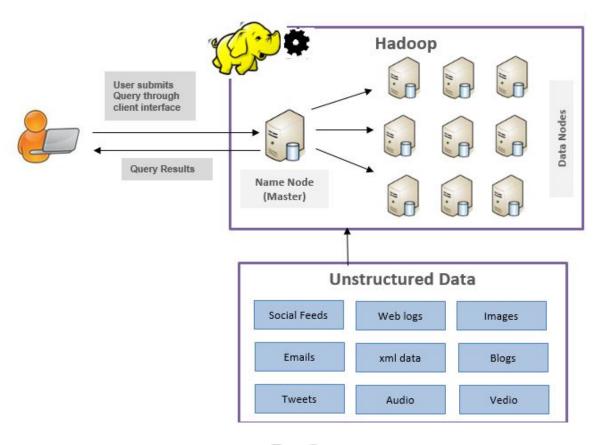
Involucra tener una base de datos o sistema anlítico separado de la transaccional.

Los procesos ETLs extraen los datos de los sistemas transaccionales y los llevan a las bases de datos OLAP luego de transformarlos.



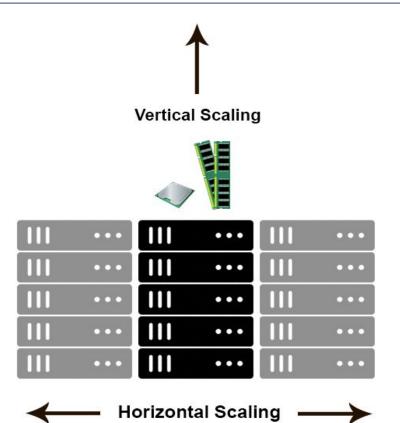
Qué es un cluster?





Cómo escalar?





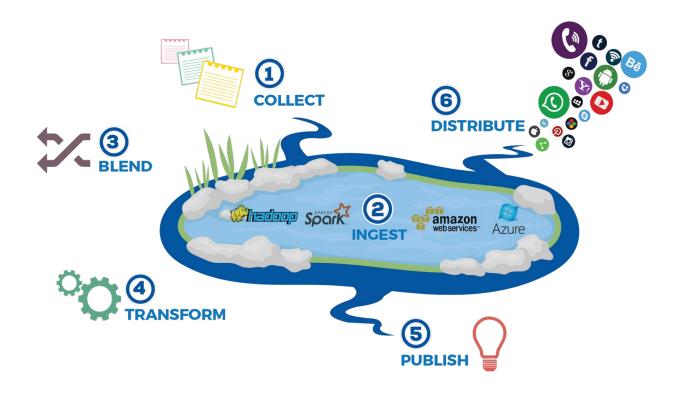
Pets vs Cattle





Data Lake





Apache Spark



Apache Spark



Es un **sistema general de procesamiento de datos a gran escala de forma distribuida**.

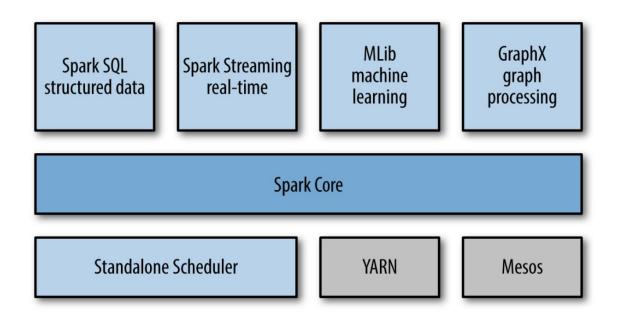
Creado en 2009 como un proyecto de research en **UC Berkeley RAD Lab.**

Provee librerías para **Scala**, **Java**, **Python** y **R** para ejecutar este procesamiento de forma distribuído.

Posibilita el procesamiento **batch**, **interactivo**, **continuo e iterativo** de forma eficiente.

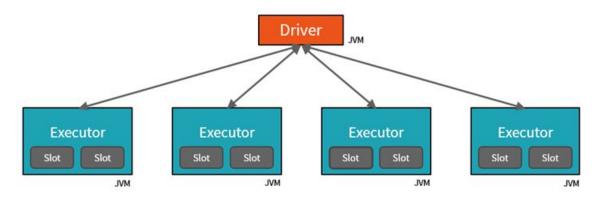
Componentes de Spark

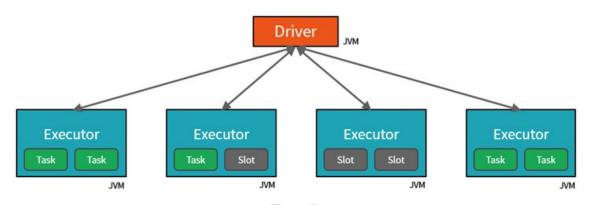




Ejecución en Apache Spark

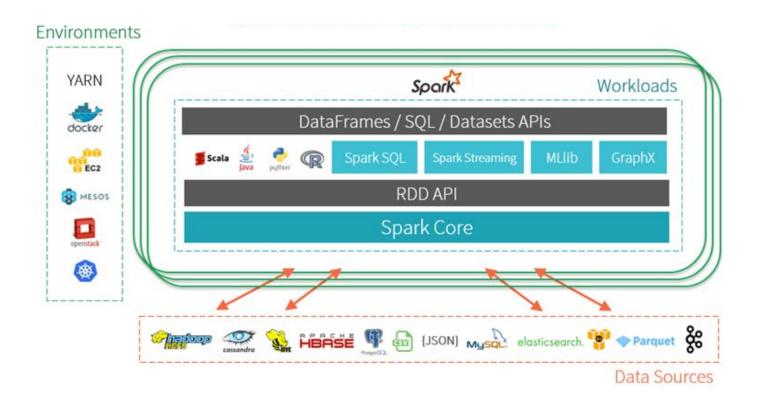






Motor unificado de procesamiento





Spark Core



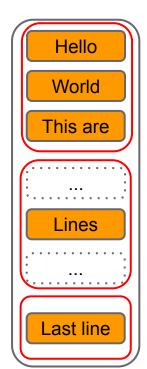
Ejecución en Apache Spark

```
DigitalHouse >
```

```
Resilient distributed
sc = SparkContext('spark://...', 'MyJob')
                                              datasets (RDDs)
file = sc.textFile('hdfs://...')
errors = file.filter(lambda line: 'ERROR' in line)
errors.cache()
                          Action
errors.count()
```

RDD: Resilient Distributed Dataset





- Colección **inmutable** de objetos.
- Particionada y distribuida.
- Almacenada en **memoria** (permite spill a disk).
- Las particiones se re-computan ante un fallo.
- Hay RDD de distintos tipos y definen:
 - una serie de particiones
 - dependencia de una partición de su RDD padre
 - función para computar una partición

Transformaciones vs Acciones



- Transformaciones: son
 operaciones sobre RDDs que se
 ejecutan de manera lazy y
 generan otro RDD.
- Acciones: son operaciones que se ejecutan en el momento y que combinan la serie de transformaciones acumuladas para obtener un resultado.

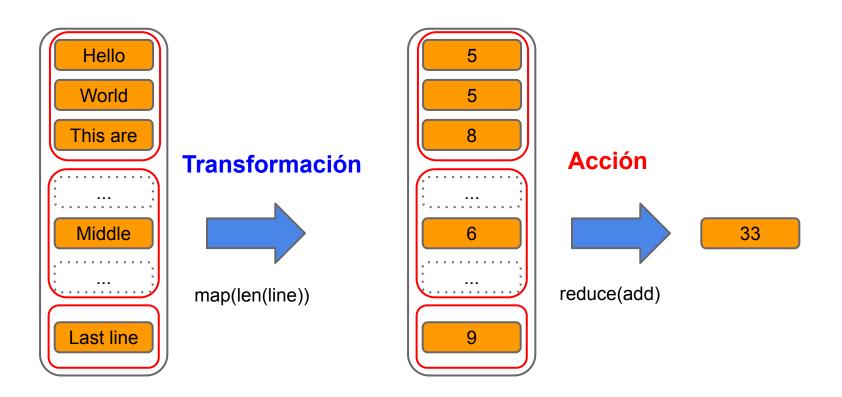




	* *
Transformations (lazy)	Actions
select	show
distinct	count
groupBy	collect
sum	save
orderBy	
filter	
limit	

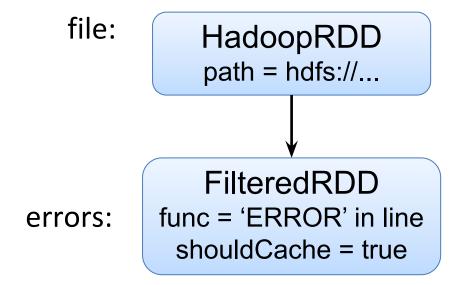
Transformaciones vs Acciones

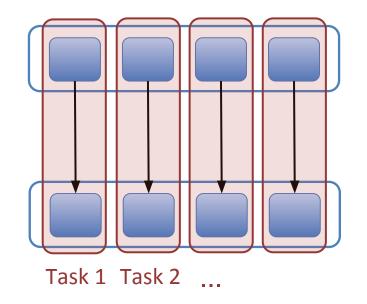




Grafo de RDDs y Tareas

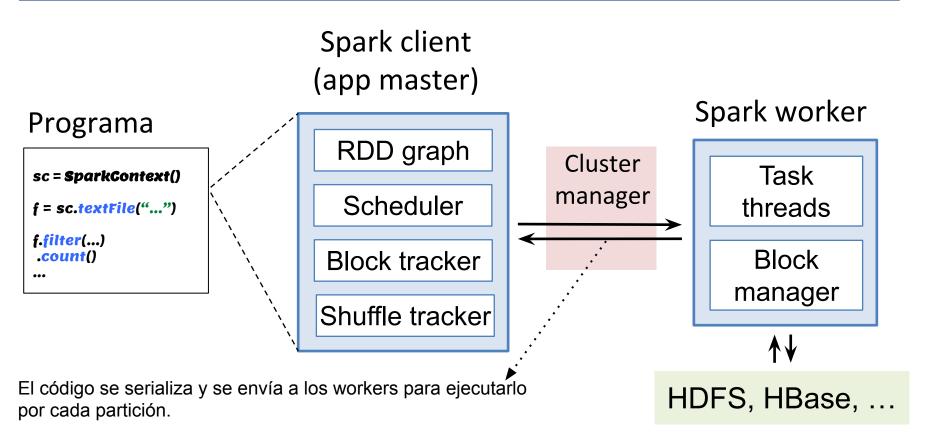






Ejecución de un programa de Spark

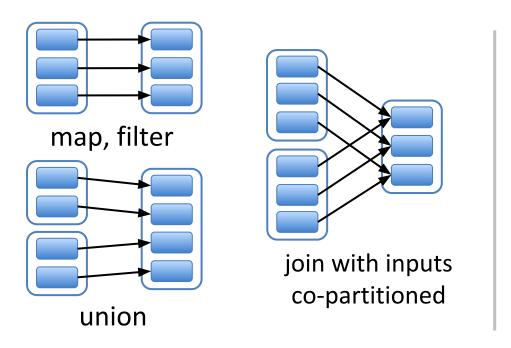




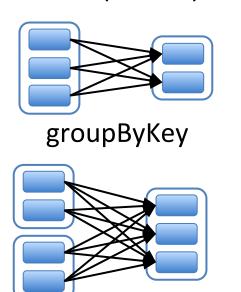
Tipos de dependencias entre RDDs



"Narrow" (pipeline-able):



"Wide" (shuffle):



PySpark



sc.textFile("/data") .filter(lambda s: "foobar" in s) .count() Python Spark Python Driver

/data

Java-to-Python communication is expensive!

Worker

Spark

Worker

Cluster

Python

Python

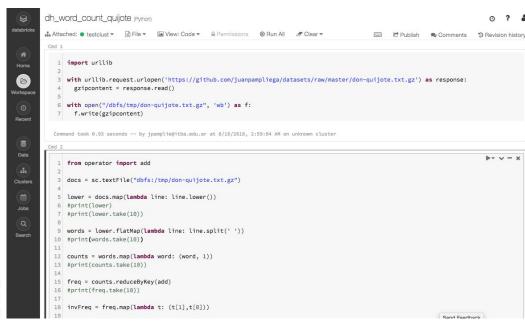
Python

Python

Databricks





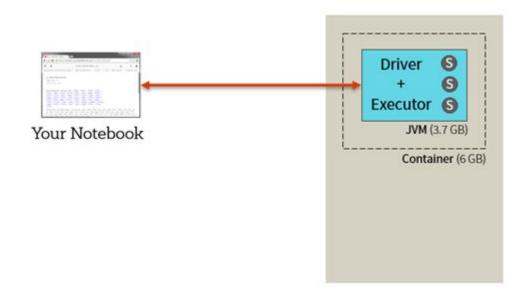


https://community.cloud.databricks.com - Community Edition

Google Cloud Platform

Databricks Community Edition





https://community.cloud.databricks.com - Community Edition

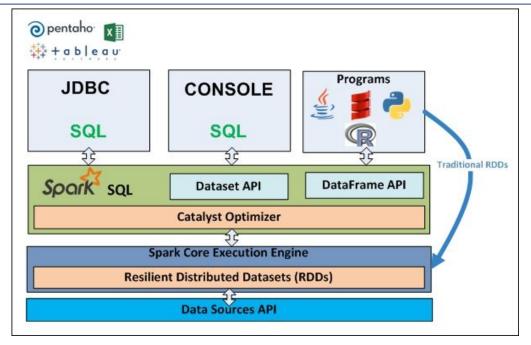
Práctica Spark Core



Spark SQL







Módulo de Spark para procesamiento de datos estructurados. Tiene un objeto de tipo DataFrame (como Pandas) pero distribuído

Spark SQL



```
from pyspark.sql import SparkSession

spark = SparkSession \
    .builder \
    .appName("Python Spark SQL basic example") \
    .config("spark.some.config.option", "some-value") \
    .getOrCreate()
```

```
# spark, df are from the previous example
# Print the schema in a tree format
df.printSchema()
# root
# |-- age: long (nullable = true)
# |-- name: string (nullable = true)
# Select only the "name" column
df.select("name").show()
# | name|
# +-----
# |Michael|
# | Andy|
# | Justin|
# +----+
# Select everybody, but increment the age by 1
df.select(df['name'], df['age'] + 1).show()
# +-----+
# | name|(age + 1)|
# |Michael| null|
# | Andy|
              31|
# | Justin|
# +-----+
# Select people older than 21
df.filter(df['age'] > 21).show()
# |age|name|
# +----+
# | 30 | Andy |
# Count people by age
df.groupBy("age").count().show()
# +----+
# | age|count|
# +----+
# | 19 | 1 |
# |null| 1|
# | 30 | 1 |
# +----+
```

Spark SQL



```
from pyspark.sql import Row
sc = spark.sparkContext
# Load a text file and convert each line to a Row.
lines = sc.textFile("examples/src/main/resources/people.txt")
parts = lines.map(lambda l: l.split(","))
people = parts.map(lambda p: Row(name=p[0], age=int(p[1])))
# Infer the schema, and register the DataFrame as a table.
schemaPeople = spark.createDataFrame(people)
schemaPeople.createOrReplaceTempView("people")
# SQL can be run over DataFrames that have been registered as a tabl
teenagers = spark.sql("SELECT name FROM people WHERE age >= 13 AND a
ge <= 19")
# The results of SQL queries are Dataframe objects.
# rdd returns the content as an :class:`pyspark.RDD` of :class:`Row
teenNames = teenagers.rdd.map(lambda p: "Name: " + p.name).collect()
for name in teenNames:
    print(name)
# Name: Justin
```

Spark SQL: Load y Save



```
df = spark.read.load("examples/src/main/resources/users.parquet")
df.select("name", "favorite_color").write.save("namesAndFavColors.parquet")
```

```
df = spark.read.load("examples/src/main/resources/people.json", format="json")
df.select("name", "age").write.save("namesAndAges.parquet", format="parquet")
```

```
df = spark.sql("SELECT * FROM parquet.`examples/src/main/resources/users.parquet`")
```

Práctica Spark SQL



CONCLUSIONES



Apache Spark



35

- Spark es el standard de facto para procesamiento distribuído.
- Spark se puede usar en Python a través de la API de PySpark.
- Por default uno utiliza siempre los Dataframes de Spark SQL.
- Al utilizar SparkSQL uno evita el overhead de serialización de código entre la JVM y Python.